

DOCUMENTAZIONE PROGETTO

KARE: Sistema Ibrido per la Diagnosi e la Pianificazione della Manutenzione su Turbine Eoliche

Integrazione di Conoscenza Simbolica, Reti Bayesiane e CSP per la Manutenzione Predittiva di un Parco Eolico

- **GRUPPO DI LAVORO:** Michele Carbonara, 802895, m.carbonara41@studenti.uniba.it
- **REPOSITORY DEL PROGETTO:** <https://github.com/michikaito/WindTurbines-PHM.git>
- **AA 2025-2026**

Sintesi del lavoro: Questo progetto nasce con l'idea di realizzare un sistema di manutenzione predittiva per turbine eoliche che non si limiti a predire un'etichetta tramite un modello black-box, ma che sia in grado di spiegare il motivo delle anomalie e di produrre un piano operativo concreto per i tecnici. È il frutto della combinazione di tre tenciche affrontate a lezione: una Knowledge Base con regole fisiche, una Rete Bayesiana per trattare l'incertezza dei sensori e un problema CSP per incastrare gli interventi rispettando le squadre disponibili e le previsioni meteo.

Indice dei Contenuti

Sezione	Contenuto trattato	Rif.
1. Introduzione e Obiettivi	Perché le turbine eoliche, problemi della manutenzione a tempo e idea di base.	Sez. 1
2. Architettura del Sistema	Come comunicano i moduli e come è stato evitato il data leakage con GroupKFold.	Sez. 2
3. Il Dataset SCADA Scelto	Origine dati, matrice di correlazione sensori, feature rolling e calcolo della RUL.	Sez. 3
4. Knowledge Base e Motore a Regole	Fatti atomici, regole diagnostiche, assunzione del mondo chiuso e matrice di confusione.	Sez. 4
5. Trattamento dell'Incertezza (Bayes)	Struttura DAG, stima Dirichlet, Failure Risk Index e matrice di confusione probabilistica.	Sez. 5
6. Pianificazione Interventi con CSP	Variabili, vincoli operativi e meteo, funzione di costo e piano Gantt.	Sez. 6
7. Risultati e Confronto Sperimentale	Validazione a 5 fold, confronto con classificatori standard e conclusioni.	Sez. 7
Appendice e Riferimenti	Organizzazione del codice Python e riferimenti bibliografici.	App.

1. Introduzione e Obiettivi del Progetto

1.1 Il problema della manutenzione nei parchi eolici

Le turbine eoliche moderne sono macchine complesse e costose, spesso posizionate in zone isolate o in mare aperto. Quando una turbina si guasta all'improvviso, l'azienda subisce due danni enormi: il mancato guadagno per l'energia non prodotta (che per una turbina da 2 MW si aggira sui 120 euro l'ora) e il costo esorbitante delle riparazioni in emergenza, che richiedono gru speciali e personale in quota.

Fare manutenzione a calendario fisso (ad esempio mandare i tecnici ogni 6 mesi) non è la soluzione migliore: spesso si interviene su componenti ancora sani sprecando risorse, oppure il guasto compare prima dell'ispezione programmata. L'approccio migliore è la manutenzione predittiva basata sulle condizioni reali della macchina (Condition-Based Maintenance).

1.2 Perché un approccio ibrido e non un semplice modello di ML?

Se addestriamo una semplice rete neurale o un albero di decisione sui dati dei sensori, il modello ci restituirà una probabilità o una classe, ma non ci saprà dire perché ha rilevato quel guasto. Inoltre, sapere che una macchina è a rischio non basta per organizzare il lavoro: bisogna decidere chi mandare, in che giorno e se il meteo permette di salire in sicurezza sulla navicella.

Per questo motivo il sistema KARE (Knowledge-Aware Reasoning Engine, Sistema Ibrido per la Diagnosi e la Pianificazione della Manutenzione) è stato suddiviso in tre moduli distinti:

- **1. Motore a Regole (Knowledge Base):** riceve i dati dei sensori e applica regole logiche basate sulle conoscenze fisiche della turbina per dire chiaramente cosa non va (es. moltiplicatore surriscaldato o perdita di pressione).
- **2. Rete Bayesiana:** costituisce la parte di Aware Reasoning, prende i sintomi e le diagnosi della KB e calcola la probabilità effettiva di guasto, tenendo conto del fatto che i sensori possono sbagliare o avere rumore.
- **3. Ottimizzatore a Vincoli (CSP):** prende le turbine a rischio e decide il calendario settimanale dei tecnici, rispettando il numero di squadre e bloccando i lavori se c'è troppo vento.

KARE Architecture: Integrazione Ibrida Knowledge-Based, Bayes e CSP




Figura 1 - Schema generale del sistema KARE: dai dati SCADA al piano di lavoro dei tecnici

2. Architettura del Sistema e Metodologia

2.1 Riferimento agli argomenti del programma

Argomento Programma ICon	Componente specifica del sistema	Istanze nel progetto
KBS e Architetture Ibride	Architettura globale KARE	Separazione esplicita tra dati telemetrici grezzi, base di conoscenza simbolica, modello probabilistico e modulo prescrittivo combinatorio.
Ragionamento con vincoli	CSP manutentivo	Variabili binarie, domini finiti, hard constraints (unicità, scadenze critiche, capacità squadre, sicurezza vento) e funzione di scoring.
Rappresentazione proposizionale	Motore di Inferenza Logico	Valutazione tramite Forward Chaining Lineare, uso della CWA
Apprendimento supervisionato	Validazione del modello	Valutazione quantitativa contro modelli supervisionati classici (<i>Dummy, Logistic Regression, Decision Tree, Gaussian Naïve Bayes</i>) su metriche bilanciate (<i>F1-Macro, Balanced Accuracy, Brier Score</i>).
Ragionamento e Incertezza	Rete Bayesiana	Grafo aciclico diretto (DAG) per la stima del Failure Risk Score combinando evidenze sensoristiche e output della KB.
Apprendimento e Incertezza	Stima CPD	Apprendimento dei parametri CPT con Bayesian Estimator e pseudo-counts

2.2 Come comunicano i moduli tra loro

La pipeline funziona a cascata in 4 passaggi principali:

Fase	File sorgente	Cosa fa	Cosa passa al modulo successivo
1. Preprocessing	scada_preprocessor.py	Pulisce le serie SCADA e calcola medie mobili	DataFrame con sensori e Z-Score
2. Diagnosi KB	logic_engine.py	Valuta le regole e assegna gli allarmi	Fatti booleani e urgenza dell'intervento
3. Stima Bayesiana	bayesian_learner.py	Esegue l'inferenza probabilistica sul grafo causale	Punteggio di rischio da 0 a 1
4. Schedulazione CSP	csp_scheduler.py	Risolve il problema di assegnazione con OR-Tools	Tabella finale con turni e giorni

2.3 Problema del Data Leakage: GroupKFold sulle turbine

Uno dei rischi maggiori con i dati temporali è il data leakage. Se prendiamo tutte le righe del dataset e le mescoliamo a caso tra training e test, il modello vedrà ore diverse della stessa turbina sia in addestramento che in test. In questo modo otterrebbe un'accuratezza altissima e finta, perché starebbe solo memorizzando la macchina.

Per evitare questo errore è stato applicato un GroupKFold su turbine_id (Figura 2). L'intera storia di una turbina finisce o tutta nel training o tutta nel test. In questo modo testiamo se il sistema è capace di diagnosticare guasti su turbine mai viste prima.




Figura 2 - Differenza tra split casuale (sbagliato) e GroupKFold raggruppato per turbina (corretto)

3. Il Dataset SCADA Scelto e l'Ingegneria dei Dati

3.1 Origine e Caratteristiche delle Serie Temporal

Per questo studio è stato scelto un dataset di telemetria SCADA (Supervisory Control and Data Acquisition) tipico dei moderni parchi eolici commerciali. Il dataset monitora una flotta di 35 turbine eoliche industriali da 2.0 MW con rotore a tre pale (diametro ~90 metri), registrando osservazioni su base oraria per oltre 12.500 record complessivi.

Ciascun record rappresenta lo stato operativo istantaneo di una determinata turbina (identificata da turbine_id) e raccoglie misurazioni fisiche provenienti da sensori distribuiti su navicella, torre e mozzo:

Sensore SCADA	Unità	Componente monitorato	Significato fisico e diagnostico
wind_speed_ms	m/s	Anemometro navicella	Velocità del vento: indica l'energia disponibile nell'ambiente.
gearbox_oil_temp_c	°C	Moltiplicatore di giri	Temperatura dell'olio: se sale troppo, perde viscosità e usura gli ingranaggi.
gearbox_bearing_temp_c	°C	Cuscinetto albero veloce	Temperatura del cuscinetto: rileva attriti meccanici e micro-fratture.
generator_winding_temp_c	°C	Avvolgimenti Generatore	Se scalda troppo rischia di danneggiare l'isolamento elettrico.
hydraulic_pressure_bar	Bar	Circuito Pitch pale	Pressione del fluido: serve a frenare e orientare le pale nel vento.
generator_rpm	RPM	Albero Generatore	Velocità di rotazione veloce (rapporto di trasmissione ~1:90 rispetto al rotore).
active_power_kw	kW	Potenza elettrica	Potenza immessa in rete: confrontata con la curva teorica rileva cali di resa.

3.2 Analisi della Matrice di Correlazione tra i sensori

Prima di impostare le regole e la rete probabilistica, è stata analizzata la matrice di correlazione tra le grandezze fisiche (Figura 3). I coefficienti evidenziano relazioni coerenti con la fisica dell'impianto:

- **Forte correlazione positiva (+0.89) tra temperatura olio e temperatura cuscinetto:** olio e cuscinetto scaldano insieme man mano che gli attriti e i carichi aumentano.
- **Marcata correlazione negativa (-0.85 e -0.93) tra temperature e pressione idraulica:** quando la macchina si surriscalda o l'impianto va sotto sforzo critico, il circuito idraulico del pitch manifesta perdite di tenuta e cali di pressione importanti.

- **Correlazione positiva (+0.46) tra potenza attiva e calore del moltiplicatore:** a regimi di vento maggiori la potenza sale, determinando un incremento proporzionale del carico termico sul moltiplicatore.




Figura 3 - Matrice di correlazione empirica tra i parametri sensoriali SCADA e le variabili di stato

3.3 Calcolo della RUL e classi di salute

Nei dati storici conosciamo l'istante in cui la macchina ha manifestato il guasto finale (t_{failure}). Viene eseguito il calcolo della Remaining Useful Life (RUL) come $RUL(t) = t_{\text{failure}} - t$ con un tetto massimo a 125 ore (Early Cutoff) per stabilizzare i modelli statistici. I dati sono stati poi discretizzati nelle tre classi di salute:

- **HEALTHY (0) - RUL > 300 ore:** turbina in funzionamento regolare (circa il 62% del dataset).
- **WARNING (1) - 100 < RUL ≤ 300 ore:** primi sintomi di degrado termico o calo di resa (circa il 23%).
- **CRITICAL (2) - RUL ≤ 100 ore:** guasto imminente, necessaria riparazione prima della rottura (circa il 15%).




Figura 4 - Distribuzione dei campioni SCADA nelle tre classi di salute RUL

3.4 Feature Engineering: Medie mobili e Z-Score contro le raffiche

Il vento è turbolento per natura e una raffica improvvisa può causare un picco di temperatura momentaneo. È stata calcolata la media mobile e lo Z-Score mobile su una finestra di 20 ore: se lo Z-Score supera 2.5 deviazioni standard, significa che la temperatura sta divergendo in modo continuo (Figura 5).




Figura 5 - Deriva termica dell'olio e superamento della soglia Z-Score statistica (2.5σ)




Figura 6 - Traiettorie di degradazione della RUL osservate su turbine distinte della flotta

Questo filtraggio statistico permette di eliminare i falsi allarmi dovuti a sbalzi transitori e di catturare solo i veri trend di surriscaldamento. In questo modo, il motore a regole riceve evidenze pulite ed evita di far scattare diagnosi critiche quando la macchina è ancora in condizioni di normale operatività.

4. Motore Diagnostico a Regole (Knowledge Base)

4.1 Fatti atomici

A ogni ora il modulo `logic_engine.py` legge la riga dei sensori e valuta i fatti atomici booleani secondo le soglie ingegneristiche (norma IEC 61400): questi predicati costituiscono la base di conoscenza estensionale e trasformano i valori continui della telemetria in simboli discreti direttamente interpretabili dal motore logico. L'attivazione congiunta di uno o più fatti funge da preconditione per le regole di inferenza, permettendo di mappare tempestivamente le anomalie fisiche prima che si trasformino in guasti irreversibili.

Fatto Atomico	Condizione di verifica	Significato fisico
gearbox_oil_high	gearbox_oil_temp_c >= 80.0 °C	L'olio del moltiplicatore è caldo ma non ancora critico.
gearbox_oil_critical	gearbox_oil_temp_c >= 95.0 °C	Temperatura olio oltre il limite di sicurezza.
bearing_temp_critical	gearbox_bearing_temp_c >= 90.0 °C	Cuscinetto albero veloce surriscaldato.
hydraulic_pressure_low	hydraulic_pressure_bar < 140.0 Bar	Pressione del circuito idraulico in calo.
hydraulic_pressure_critical	hydraulic_pressure_bar < 125.0 Bar	Pressione troppo bassa per garantire il pitch sicuro.
generator_winding_critical	generator_winding_temp_c >= 115.0 °C	Avvolgimenti del generatore vicini al limite termico.
power_underperformance	Potenza effettiva / Potenza teorica < 0.70	La turbina produce meno del 70% di quanto dovrebbe.
thermal_runaway	ZScore olio > 2.5 oppure ZScore cuscinetto > 2.5	Deriva di calore continua e anomala.

4.2 Regole di inferenza e azioni suggerite

Il motore applica il Forward Chaining sotto l'assunzione del mondo chiuso (Closed World Assumption): se una condizione anomala non viene provata dalle regole, è considerata assente.

Regola	Condizione logica	Diagnosi prodotta	Azione e Scadenza
R1	(olio critico O cuscinetto critico) E deriva termica	Guasto meccanico moltiplicatore	Sostituzione (entro 2 gg)

R2	olio alto MA NON critico	Surriscaldamento olio	Ispezione filtro/radiatore (7 gg)
R3	pressione idraulica critica	Rischio blocco attuatore pitch	Riparazione urgente (2 gg)
R4	pressione bassa MA NON critica	Perdita idraulica moderata	Controllo perdite (4 gg)
R5	generatore critico E oltre 1800 RPM	Rischio guasto elettrico generatore	Sostituzione (2 gg)
R6	bassa resa MA pressione idraulica ok	Disallineamento aerodinamico pale	Ispezione angoli di pitch (7 gg)

4.3 Valutazione della KB e Matrice di Confusione Diagnostica

Per verificare la bontà della Knowledge Base è stato eseguito il confronto tra lo stato diagnosticato dalle regole e lo stato reale (RUL Ground Truth) su tutti i fold di validazione.

Stato Reale (Ground Truth)	Predetto HEALTHY	Predetto WARNING	Predetto CRITICAL	Totale Reali
HEALTHY (Reale)	7.210 (92.8%)	480 (6.2%)	80 (1.0%)	7.770 (100%)
WARNING (Reale)	320 (11.1%)	2.280 (79.2%)	280 (9.7%)	2.880 (100%)
CRITICAL (Reale)	15 (0.8%)	125 (6.7%)	1.710 (92.5%)	1.850 (100%)

Analisi della Matrice di Confusione della KB

Il risultato più importante per la sicurezza dell'impianto è la cella [CRITICAL, HEALTHY] (falsi negativi gravi), che si attesta su appena lo 0.8% (15 campioni su 1.850). Questo significa che il motore a regole quasi mai ignora un componente che sta per rompersi, garantendo un Recall del 92.5% sulla classe critica.




Figura 7 - Grafo delle regole della Knowledge Base e frequenza di attivazione delle diagnosi

Come evidenziato dal grafico delle frequenze di attivazione, la maggior parte delle finestre temporali viene classificata come NONE, a conferma del fatto che la flotta opera prevalentemente in regime stazionario nominale. Tra le diagnostiche scattano con maggiore frequenza spicca WARN_GEARBOX_OIL_OVERHEAT, che indica il surriscaldamento del moltiplicatore di giri come causa primaria di degrado termomeccanico. Le attivazioni multiple congiunte (come il surriscaldamento combinato di olio, cuscinetti e avvolgimenti) presentano frequenze progressivamente inferiori ma corrispondono agli scenari a più alto rischio, fornendo alla successiva Rete Bayesiana evidenze tracciabili.

5. Trattamento dell'Incertezza con la Rete Bayesiana

5.1 La struttura del grafo causale

La Knowledge Base fornisce una valutazione deterministica, ma i sensori possono presentare rumore o letture imprecise. Il modulo `bayesian_learner.py` integra un Grafo Aciclico Diretto (DAG) in cui i fatti della KB diventano evidenze osservate:

Topologia Causale della Rete Bayesiana (DAG)




Figura 8 - Topologia della Rete Bayesiana: relazioni causali tra vento, componenti e salute

Nodo del Grafo	Stati possibili	Cosa rappresenta
wind_regime	Basso, Nominale, Alto	Velocità del vento (influenza sforzo meccanico ed elettrico).
gearbox_thermal_state	Safe, Warning, Critical	Stato di calore del moltiplicatore legato al vento.
bearing_stress	Normale, Alto Stress	Stress sui cuscinetti generato dal calore del moltiplicatore.
hydraulic_status	Nominale, Bassa Pressione	Tenuta del circuito di orientamento delle pale.
power_efficiency	Nominale, Sotto-rendimento	Resa energetica calcolata rispetto al vento.
health_state (Target)	HEALTHY, WARNING, CRITICAL	La variabile obiettivo che vogliamo stimare.

5.2 Stima CPT con Dirichlet e Failure Risk Score

Sono state stimate le CPT usando il Bayesian Estimator con prior Dirichlet e pseudo-counts a 10 (smoothing BDeu) per evitare probabilità nulle su stati rari: poiché i guasti gravi sono eventi rari nei dati storici, questo accorgimento evita che il modello consideri del tutto "impossibile" (probabilità zero) una combinazione critica solo perché non si è ancora verificata nel dataset. Una volta addestrata la rete, applichiamo l’algoritmo Variable Elimination per calcolare la probabilità aggiornata dello stato di salute in base ai sensori rilevati: $P(\text{health_state} \mid \text{Evidenze})$. Da queste probabilità ricaviamo infine un unico indice di rischio continuo compreso tra 0 e 1:

$$\text{FailureRiskScore} = 0.40 * P(\text{WARNING}) + 1.00 * P(\text{CRITICAL})$$

Questa formula ha il compito di sintetizzare l'incertezza in un valore intuitivo: assegna un peso moderato (40%) ai segnali di usura iniziale e un peso totale (100%) al rischio di rottura imminente, fornendo al successivo modulo di pianificazione (CSP) una priorità chiara e graduale per decidere quali turbine riparare per prime.

5.3 Matrice di Confusione e Calibrazione Bayesiana

La tabella seguente riporta la matrice di confusione media ottenuta dalla Rete Bayesiana su validazione GroupKFold:

Stato Reale (Ground Truth)	Predetto HEALTHY	Predetto WARNING	Predetto CRITICAL	Totale Reali
HEALTHY (Reale)	7.150 (92.0%)	540 (7.0%)	80 (1.0%)	7.770 (100%)
WARNING (Reale)	260 (9.0%)	2.380 (82.6%)	240 (8.4%)	2.880 (100%)
CRITICAL (Reale)	10 (0.5%)	145 (7.8%)	1.695 (91.7%)	1.850 (100%)

Analisi della Matrice Bayesiana

Rispetto alle sole regole deterministiche, la Rete Bayesiana migliora sensibilmente la gestione delle situazioni incerte: la capacità di riconoscere lo stato intermedio di *WARNING* sale dal 79.2% all'82.6%, evitando di scambiare turbine usurate per sane e riducendo il Brier Score complessivo a 0.115 (indice di previsioni probabilistiche affidabili e ben calibrate)




Figura 9 - Andamento nel tempo del Failure Risk Score rispetto al degrado reale

Come si osserva nella Figura 9, il punteggio di rischio (linea rossa) segue fedelmente il reale percorso di usura della turbina nel tempo:

- **Fase iniziale (0–50 ore):** la turbina è in salute; il rischio calcolato rimane basso e non fa scattare falsi allarmi.
- **Fase intermedia (50–250 ore):** compaiono i primi sintomi di surriscaldamento; l'indice sale stabilmente intorno a 0.40–0.50 segnalando lo stato di attenzione (*WARNING*).
- **Fase finale (dopo le 250 ore):** il degrado accelera e l'indice schizza verso il valore massimo (1.0), intercettando in pieno lo stato critico (*CRITICAL*) ben prima del collasso effettivo del componente.

6. Pianificazione della Manutenzione con CSP

6.1 Formulazione del problema a vincoli

Il modulo `csp_evaluation.py` modella la pianificazione settimanale come un CSP risolto con Google OR-Tools CP-SAT. Le variabili binarie $X[t, d, c]$ indicano se la turbina t viene riparata nel giorno d dalla squadra c .

Modellazione Matematica e Vincoli CSP




Figura 10 - Schema formale dei vincoli operativi e della funzione obiettivo del CSP

6.2 I vincoli da rispettare (Hard Constraints)

- **1. Unicità dell'intervento:** una turbina guasta riceve al massimo un intervento durante la settimana di lavoro.
- **2. Rispetto delle scadenze critiche:** se una turbina è in stato CRITICAL (o ha una deadline di 2 giorni dalla KB), deve essere per forza riparata entro quel limite di tempo.
- **3. Limite di lavoro per squadra:** un intervento richiede circa 8 ore di lavoro; ogni squadra non può fare più di una turbina al giorno.
- **4. Sicurezza meteo:** per legge e sicurezza dei tecnici, se le previsioni meteo indicano vento sopra i 12 m/s è vietato salire in navicella. Il solutore blocca gli interventi in quei giorni.

6.3 Minimizzazione dei costi e piano Gantt

Il solutore trova l'assegnazione valida che costa meno: considera il costo base dell'intervento (1.500 euro per ispezione, 6.500 euro per riparazione grave), penalizza i giorni di ritardo e applica multe altissime se una turbina critica viene lasciata indietro non riparata.

Come mostrato nel Gantt (Figura 11):

- **Giorni 1–2 (Blocchi rossi):** Gli interventi critici (WTG_04, WTG_12, WTG_09) vengono risolti subito nei primi turni utili per rispettare la scadenza di sicurezza.
- **Giorni 3–5 (Blocchi blu):** Vengono programmate le ispezioni preventive moderate (WTG_18, WTG_22, WTG_31, WTG_07) distribuendole sulla capienza delle squadre.
- **Regole operative:** Ciascuna squadra esegue al più una turbina al giorno, mentre i turni restano vuoti nei giorni con previsioni di vento forte oltre i 12 m/s.




Figura 11 - Piano settimanale Gantt generato da OR-Tools: assegnazione delle squadre nei giorni sicuri

7. Valutazione Sperimentale e Conclusioni

7.1 Confronto con baseline standard di Machine Learning

È stato confrontato KARE con classificatori standard (Dummy Classifier, Logistic Regression, Decision Tree, Gaussian Naive Bayes) usando lo stesso protocollo GroupKFold a 5 Fold:

Modello	F1-Macro	Balanced Accuracy	Accuracy	Tempo calcolo	Spiegabilità del motivo
Dummy (Most Frequent)	0.220 ± 0.000	0.333 ± 0.000	0.620 ± 0.000	< 0.01 s	Nessuna (predice sempre sano)
Logistic Regression	0.685 ± 0.024	0.710 ± 0.021	0.782 ± 0.018	0.45 s	Bassa (solo pesi numerici)
Decision Tree (Depth=6)	0.742 ± 0.022	0.760 ± 0.019	0.815 ± 0.015	0.12 s	Media (albero di soglie fisse)
Gaussian Naive Bayes	0.630 ± 0.028	0.675 ± 0.025	0.740 ± 0.020	0.08 s	Bassa (assume indipendenza)
KARE (KB + Bayes + CSP)	0.865 ± 0.020	0.885 ± 0.018	0.894 ± 0.015	0.25 s	Totale (Regole + Probabilità + Turni)

I dati della tabella evidenziano chiaramente perché l'approccio ibrido di KARE sia la scelta migliore rispetto ai modelli di machine learning tradizionali:

- **Il tranello dell'Accuracy:** Il modello banale (*Dummy Classifier*) ottiene un'accuratezza apparentemente decente del 62%, ma solo perché "tira a indovinare" la classe più frequente dicendo che la turbina è sempre sana. Il suo F1-Macro crolla a 0.220, dimostrando che non intercetta alcun guasto.
- **Superiorità predittiva:** KARE supera nettamente tutti i modelli concorrenti, raggiungendo un F1-Macro di **0.865** e una Balanced Accuracy di **0.885**, distaccando di oltre 12 punti percentuali anche il Decision Tree.
- **Spiegabilità e Azione:** Mentre i modelli standard forniscono solo un'etichetta numerica "a scatola chiusa", KARE non solo offre una precisione superiore in tempi rapidissimi (0.25 s), ma fornisce la motivazione fisica della diagnosi (grazie alle regole della KB) e genera direttamente il piano operativo per i tecnici sul campo (grazie al CSP).

7.2 Considerazioni finali

L'esperienza di sviluppo ha dimostrato che unire la logica basata su regole e la probabilità bayesiana permette di ottenere un sistema molto più affidabile rispetto all'uso di un singolo modello. La Knowledge Base permette ai tecnici di capire subito quale componente si sta rompendo, la Rete Bayesiana filtra il rumore e il CSP agevola la pianificazione operativa incastrando automaticamente le squadre con le finestre meteo favorevoli e le priorità d'intervento.

Appendice: Organizzazione del Codice

File Python	A cosa serve nel progetto	Come si lancia
wt_config.py	Contiene le costanti, le soglie dei sensori e i parametri dei modelli.	Importato dai moduli
scada_preprocessor.py	Carica i dati SCADA, calcola le feature rolling e la RUL.	python scada_preprocessor.py
logic_engine.py	Valuta i fatti atomici e le regole diagnostiche della KB.	python logic_engine.py
bayesian_learner.py	Costruisce la rete bayesiana ed esegue l'inferenza del rischio.	python bayesian_learner.py
csp_scheduler.py	Formula e risolve il problema CSP dei turni con OR-	python csp_scheduler.py

Tools.

main.py	Lancia l'intera pipeline dall'inizio alla fine su tutta la flotta.	python main.py
experiment_runner.py	Esegue tutti i test di cross-validation e genera i CSV comparativi.	python experiment_runner.py

Riferimenti Bibliografici

- [1] D. Poole, A. Mackworth, Artificial Intelligence: Foundations of Computational Agents, Cambridge University Press, 2023.
- [2] J. Pearl, Probabilistic Reasoning in Intelligent Systems, Morgan Kaufmann, 1988.
- [3] F. Rossi, P. van Beek, T. Walsh, Handbook of Constraint Programming, Elsevier, 2006.
- [4] Standard Internazionale IEC 61400-4: Requisiti di progettazione per moltiplicatori di turbine eoliche, 2012.
- [5] Documentazione ufficiale Google OR-Tools (CP-SAT Solver) e pgmpy per Reti Bayesiane discrete in Python.